# 모델링 결과서

| | |
|---|---|
| 접수번호 | A616277 |
| 팀명 | 몰루미늄 |
| 공모전 중복 참여 여부 | 2026 AI·SW중심대학 디지털 경진대회: AI 부문 대상(부총리 겸 과학기술정보통신부장관상) |
| 주요 활용 라이브러리 | Python, PyTorch, segmentation_models_pytorch, torchvision, timm, Albumentations, OpenCV, NumPy, SciPy |

## 배경 및 아이디어 소개(요약)

□ **아이디어 제안 배경**

- **목표:** 고탄성 알루미늄 합금 현미경 이미지에서 $Al_3Ni$, Primary Si, Al, Eutectic Si 네 상(조직)을 픽셀 단위로 구분하는 모델 개발
- **데이터 특징:** 이미지마다 밝기가 크게 다르고, Eutectic Si가 드물며, 상 사이 경계가 매우 촘촘함
- **제안 방법:** 3 단계 예측. 1) 상별 결합 앙상블(Routing ensemble, 이하 R): 상별 강점과 결합 효과를 기준으로 모델 결합 2) 전문가 앙상블(Expert ensemble, 이하 E): E가 $Al_3Ni$·Al로 판단한 픽셀을 교체(이하 덮어쓰기) 3) 최종 보정기(Final refiner, 이하 F): Al 판단을 다시 확인하는 작은 CNN

□ **파급효과**

- **작업 자동화:** 네 상의 분할을 자동화하고, 상 면적비 산출과 조직 경계 검토에 활용(검증용 상 면적비 오차 평균 0.3~1.3%p)
- **검토 효율화:** 모델 간 예측 불일치 영역을 전문가 검토·추가 라벨링 우선순위 선정에 활용하는 방향으로 확장 가능(④에서 효과 확인)
- **측정 신뢰도 향상:** 경계 오차가 상 면적비·형상 측정에 미치는 영향을 평가하고, 경계 품질과 측정 정확도를 함께 개선하는 방향으로 발전

# 고탄성 알루미늄 합금 이미지 상 분할 인공지능 모델

## 분석·모델링 결과서(10 페이지 이내)

### ① 분석(EDA) 개요

#### 1-1. 분석 핵심 내용

□ **밝기 차이:** 이미지별 평균 밝기가 139~200 으로 달라, 같은 상도 이미지에 따라 밝거나 어둡게 보임

□ **상 비율 불균형:** Al이 화면의 약 60%, Eutectic Si는 약 7%에 불과해 드문 상을 놓치기 쉬움

□ **상이 없는 이미지:** Primary Si가 없는 이미지가 학습용·검증용에 각 1 장 존재

□ **크기·배율 차이:** 비율은 약 1.41 로 같고 크기만 675×480~1440×1024 로 달라 같은 조직이 다른 배율로 보임. 학습용·평가용 4 종, 검증용 5 종(1096×780 추가)

□ **얇은 상:** Eutectic Si 픽셀의 약 84%가 상 경계 1 픽셀 이내에 있을 만큼 가늘어 경계 오차에 민감함

#### 1-2. 분석 배경

□ **평가 방식:** 이미지마다 네 상의 IoU를 평균한 뒤 20 장 평균

$$\mathrm{IoU}n,c = \frac{|Pn,c \cap G_{n,c}|}{|P_{n,c} \cup G_{n,c}|}, \qquad \mathrm{mIoU} = \frac{1}{N}\sum_{n=1}^{N}\frac{1}{4}\sum_{c=1}^{4}\mathrm{IoU}_{n,c}$$

- P·G는 이미지 n에서 상 c로 예측한·정답인 픽셀 집합, N은 이미지 수
- 정답과 예측 모두에 해당 상이 없으면 IoU = 0

- **지표의 특징:** 상과 이미지를 같은 비중으로 평균하므로 드문 상이나 한 장의 오류도 점수에 크게 반영됨

□ **핵심 과제:** 1-1 의 분석에서 점수를 좌우하는 과제 3 가지를 도출하고 전처리, 모델링에서 표 1 과 같이 대응

표 1. 점수를 좌우하는 핵심 과제와 단계별 대응

| 과제 | 데이터 분석 | 전처리 | 모델링 |
|---|---|---|---|
| ① 밝기·배율 차이 | 평균 밝기 139~200,<br>같은 비율, 크기 5 종,<br>기존 밝기로는 상이 겹침 | 세 가지 밝기 표현,<br>가로 폭 정규화 | 예측 시 적응(TENT),<br>밝기 보정 |
| ② 드문 상 | Eutectic Si 약 7%<br>(이미지별 1.5~18%) | 잘라내는 영역의 절반을<br>드문 상 주변에서 선택 | 드문 상 가중 HRNet,<br>상별 결합 |
| ③ 얇은 경계 | Eutectic Si 픽셀의 약 84%가<br>경계 1 픽셀 이내 | 2~3 배 확대 후<br>1536×1536 크기로 학습 | 고해상도 HRNet·경계 손실,<br>E 덮어쓰기, F 보정 |

### 1-3. 분석 방법 및 분석 내용

□ **상 비율:** 정답 마스크에서 상별 픽셀 비율을 학습용·검증용별로 계산(표 2)

표 2. 상별 픽셀 비율과 그 상이 들어 있는 이미지 수

| 상 | 학습용 픽셀 비율 | 검증용 픽셀 비율 | 이 상이 들어 있는 이미지 |
|---|---|---|---|
| $Al_3Ni$ | 26.31% | 21.16% | 학습용 70/70, 검증용 20/20 |
| Primary Si | 9.43% | 10.17% | 학습용 69/70, 검증용 19/20 |
| Al | 57.28% | 61.02% | 학습용 70/70, 검증용 20/20 |
| Eutectic Si | 6.98% | 7.66% | 학습용 70/70, 검증용 20/20 |

□ **이미지별 상 비율 편차:** 같은 상도 이미지별 면적 비율 편차가 큼($Al_3Ni$ 8.8~43.3%, Eutectic Si 1.5~18.0%), 드문 상이 적은 이미지에서는 몇 픽셀 오류로도 해당 상의 IoU가 크게 흔들림

□ **밝기 분포:** 가장 어두운 이미지와 가장 밝은 이미지는 같은 합금임에도 차이가 뚜렷함(그림 1)

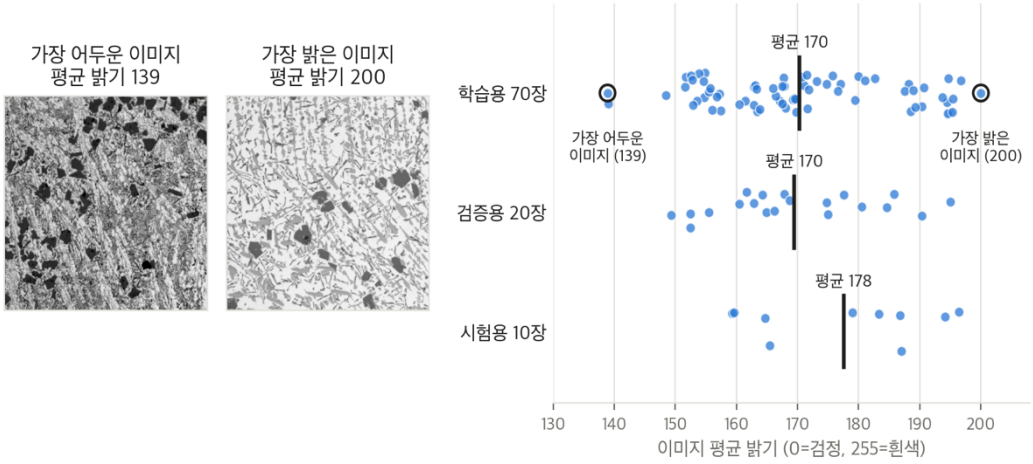



그림 1. 가장 어두운·밝은 학습용 이미지(왼쪽)와 구분별 이미지 평균 밝기(오른쪽, 검은 선은 평균)

□ **상별 밝기 겹침:** 기존 밝기로는 $Al_3Ni$와 Eutectic Si의 범위가 크게 겹침, 이미지 내 상대 밝기(Z)로 바꾸면 두 상이 거의 분리됨(표 3)

표 3. 상별 밝기 범위(기존 밝기와 이미지 내 상대 밝기 Z)

| 상 | 기존 밝기(이미지별 평균) | 상대 밝기 Z |
|---|---|---|
| $Al_3Ni$ | 103~185 | −1.0~−0.1 |
| Primary Si | 18~123 | −2.8~−1.3 |
| Al | 183~231 | +0.5~+0.9 |
| Eutectic Si | 59~149 | −1.8~−0.9 |
| $Al_3Ni$·Eutectic Si 겹침 | 103~149 (폭 46) | −1.0 ~ −0.9 (폭 0.1) |

- 학습용 70 장에서 상별 픽셀 밝기의 이미지별 평균이 놓인 범위,

  Z = (밝기 − 이미지 평균) ÷ 이미지 표준편차

## ② 데이터 전처리

### 2-1. 전처리 방법

□ **세 가지 밝기 표현:** 같은 이미지를 기존 밝기(실제 밝기 차이 보존), 상대 밝기 Z(이미지 평균 대비 밝기, 노출 차이 제거), 밝기 순위 CDF(이미지 안에서 그보다 어둡거나 같은 픽셀의 비율 0~1, 노출이 달라도 순서 유지)로 표현, Z로 $Al_3Ni$·Eutectic Si의 밝기 겹침 해소(표 3)

- **입력 정규화:** EfficientNet-B4 와 E의 세 밝기 HRNet은 세 표현을 3 채널로 쌓아 입력(EfficientNet-B4 는 이미지 전체 평균·표준편차로 정규화), ResNet34 원본 해상도는 세 표현을 3 채널로 쌓아 고정 값으로 정규화, ResNet34 고해상도·나머지 HRNet은 흑백 밝기를 3 채널로 복사해 ImageNet 평균·표준편차로 정규화, F는 Z를 ±3 에서 잘라 0~1 로 조정(이미지 평균 = 0.5)

□ **크기 맞춤:** 작은 조직을 잘 보도록 2~3 배 확대하거나 가로 4000 픽셀로 조정, 정답 마스크는 상 표시가 섞이지 않도록 최근접 보간(가장 가까운 픽셀 값 사용)

- **가로 폭 정규화(E):** 배율 차이를 줄이고자 EfficientNet-B4 는 4000 픽셀, HRNet은 학습 fold에서 가장 흔한 폭(1230·1278 픽셀)으로 맞춘 뒤 2 배 확대, R과 다른 크기로 보아 두 앙상블의 오류 중복 감소

### 2-2. 전처리 절차

□ **학습용 4-fold 분할:** 학습용 70 장을 파일명 앞 번호(예: A71)가 같은 이미지끼리 묶어 4 묶음(18·18·17·17 장)으로 고정, 한 묶음씩 빼고 학습해 fold 모델 4 개 생성

□ **학습 영역 샘플링:** 잘라내는 영역의 절반을 $Al_3Ni$·Eutectic Si 주변에서 선택, EfficientNet-B4 는 확대 이미지에서 1536×1536 영역(3 배 확대 시 원본 약 512×512)을 자르고 가로 4000 픽셀 EfficientNet-B4 는 이미지를 같은 빈도로, 나머지 EfficientNet-B4 는 면적에 비례해 선택

□ **데이터 증강:** 회전·뒤집기·확대·밝기 변화를 이미지와 정답 마스크에 같은 변환으로 적용해 다양한 촬영 조건 학습

□ **예측 시 처리:** 큰 이미지는 겹치게 잘라 예측해 이어 붙임(ResNet34 768·1024 영역을 576 픽셀 간격, HRNet 512 영역을 170 픽셀 겹침, EfficientNet-B4 는 전체 이미지), 회전·뒤집기 예측 평균(TTA: ResNet34 고해상도와 E의 EfficientNet-B4·R의 세 밝기 EfficientNet-B4 8 방향, E의 가로 폭 정규화 HRNet 4 방향) 후 원래 크기로 복원

- **밝기 표준화**(ResNet34 고해상도): 원본과 함께 밝기를 학습용 평균·표준편차에 맞춘 사본도 예측해, 이미지 밝기에 따라 정한 비율로 혼합

## ③ 모델링

### 3-1. 배경 및 알고리즘 소개

□ **개요:** 한 모델로 네 상을 모두 잘 맞히기 어려워, 상별 결합 앙상블(R)·전문가 앙상블(E)·최종 보정기(F)의 3 단계로 결합해 최종 마스크 생성(그림 2), 단독 점수가 아니라 상별 강점과 기존 오류 보완을 기준으로 모델을 결합한 것이 핵심




그림 2. 최종 모델의 전체 구조. R(7 개)과 E(5 개)의 예측을 덮어쓰기로 합친 뒤 F(1 개)로 보정(가중치 13 개)

□ **모델 구성 선택 근거**

- **기본 모델 선택:** 초기 비교에서 ResNet34 U-Net++가 최고 성능(전체 픽셀 기준 mIoU 74.44%, ConvNeXt 71.44%, SegFormer 65.56%, SAM2 44.15%, DINOv2 42.38%)
- **보조 모델 추가:** 학습법을 바꾼 뒤 EfficientNet-B4·HRNet의 성능 향상(EfficientNet-B4: 3 배 확대, 1536×1536 영역, HRNet: U-Net++ 디코더·경계 학습), 단독 점수 77~78%(표 4)
- **R 시작 확률:** 단독 최고인 EfficientNet-B4(78.83%)로 시작하면 최종 점수가 0.02~0.04%p 낮아 ResNet34 고해상도 모델을 채택
- **R (상별 결합):** 단독 최고 모델이 상마다 다름($Al_3Ni$·Eutectic Si는 ResNet34, Primary Si는 EfficientNet-B4 가로 4000, Al은 HRNet, 표 4), 모델 전체를 평균하지 않고 상별로 확률을 교체하며 비율은 결합 효과로 선택(예: Eutectic Si는 HRNet 드문 상 가중이 75%, 그림 3), 백본별 단순 평균(78.0~79.1%)보다 높은 79.80%
- **E (부분 덮어쓰기):** 단독 점수(79.59%)는 R(79.80%)보다 낮지만 $Al_3Ni$·Al로 판단한 픽셀만 교체하면 $Al_3Ni$ IoU가 76.58% → 78.23%로 올라 80.75%(+0.95%p), EfficientNet-B4 40%·HRNet 60%로 결합
- **F (Al 재확인):** 주변 7×7 의 확률·밝기로 E가 $Al_3Ni$·Eutectic Si로 잘못 본 Al 픽셀을 되돌리는 3 층 CNN, 픽셀 0.12%만 바꿔 +0.03%p

표 4. 모델별 검증용 단독 점수와 결합 단계별 점수(IoU)

| 모델(검증용 단독) | 전체 | $Al_3Ni$ | Primary Si | Al | Eutectic Si |
|---|---|---|---|---|---|
| ResNet34 | 78.72% | 75.15% | 86.04% | 93.74% | 59.95% |
| EfficientNet-B4 세 밝기 표현 | 78.04% | 73.97% | 86.25% | 93.93% | 58.01% |
| EfficientNet-B4 가로 4000 픽셀 | 78.83% | 75.13% | 86.48% | 94.05% | 59.67% |
| HRNet 기본 | 78.18% | 73.47% | 86.03% | 94.35% | 58.88% |
| HRNet 드문 상 가중 | 76.67% | 71.33% | 85.33% | 93.47% | 56.54% |
| R 결합(7 개) | 79.80% | 76.58% | 87.02% | 94.18% | 61.40% |
| E 전문가 앙상블 단독 | 79.59% | 75.70% | 86.61% | 94.52% | 61.54% |
| **최종(R + E + F)** | **80.78%** | **78.25%** | **87.33%** | **94.58%** | **62.96%** |

- 단독 점수는 백본별 fold 4 개의 예측 확률 평균(R은 이 중 일부 fold만 사용), ResNet34 만 밝기 보정 등 후처리 포함
- **앙상블 효과:** 단일 체크포인트 최고(EfficientNet-B4 가로 4000 픽셀 fold 4, 78.38%) → fold 4 개 확률 평균 최고 78.83% → 백본별 1 개씩 단순 평균 78.0~79.1% → 상별 결합·후처리·덮어쓰기 후 80.78%로, 단일 모델 대비 약 2.4%p 향상

### 3-2. 모델링 방법

□ **처리 순서:** ① 모델 학습 → ② R 상별 결합 → ③ 후처리 → ④ E 덮어쓰기 → ⑤ F 보정 순으로 최종 마스크 생성

□ **① 모델 학습:** EfficientNet-B4 와 HRNet은 4-fold로 학습한 fold 모델 중 일부를 골라 예측 확률을 평균(쓰는 fold는 표 5 참고)

표 5. 구성 모델별 입력과 학습량

| 번호 | 모델 | 역할 (결합 비중) | 입력·학습 |
|---|---|---|---|
| R1 | ResNet34 고해상도 | 시작 확률, 예측 시 이미지별 적응(TENT) (Eutectic Si 7.5%) | 768 영역, 상 구분 손실로 추가 학습 |
| R2 | ResNet34 원본 해상도 | Eutectic Si 보조 (17.5%) | 원본 해상도, 세 밝기 표현 |
| R3 | EfficientNet-B4 3 배 확대 | $Al_3Ni$ (50%, R4~R6 과 분담)·Al (18.75%) 보조 | 3 배 확대 1536 영역, 16,000 step |
| R4~R6 | EfficientNet-B4 가로 4000 (fold 1·3·4 평균) | $Al_3Ni$ (50%)·Primary Si (75%) 주력 | 가로 4000 픽셀, fold당 16,000 step |
| R7 | HRNet 드문 상 가중 | Al (81.25%)·Eutectic Si (75%) 주력, Primary Si 25% | 256→512 확대, 70+12 epoch |
| E1~E2 | EfficientNet-B4 가로 4000 추가 학습 (fold 1·3) | E의 40%, $Al_3Ni$·Al 덮어쓰기 판단 | BatchNorm 고정 2,000 step 추가 |
| E3 | HRNet 세 밝기 입력 | E4 와 평균해 E의 42% | 기본 HRNet에서 25 epoch 추가 학습 |

| 번호 | 모델 | 역할 (결합 비중) | 입력·학습 |
|---|---|---|---|
| E4 | HRNet 가로 폭 정규화 (fold 4) | E3 와 평균해 E의 42% | 70 epoch |
| E5 | HRNet 가로 폭 정규화 (70 장 전체) | 단독으로 E의 18% | 70 epoch |
| F1 | 3 층 CNN | E 결과의 AI 픽셀 재확인 | E log 확률 + 밝기, 8 epoch |

- **손실 함수:** 모든 모델이 픽셀별 분류 오차(Cross-Entropy)와 영역 겹침 오차(Dice)를 함께 최소화, HRNet은 학습 시에만 붙는 보조 출력으로 경계 영역을 예측해 그 오차를 추가(예측 시 미사용), F는 보정량 크기에 대한 벌점 추가

□ **구성 모델별 특징(표 5 번호):** 같은 백본이라도 입력·손실·학습 데이터 묶음(fold)을 달리해 서로 다른 오류를 내도록 구성, fold 모델은 4 묶음 중 하나를 뺀 약 52 장으로 학습

- **R1 ResNet34 고해상도:** $Al_3Ni$·Eutectic Si 사이의 확률 차이를 벌리는 손실을 더해 768×768 영역으로 추가 학습, 모든 이미지의 시작 확률을 만들며 예측 직전 정답 없이 정규화 층(BatchNorm)만 이미지별로 5 회 조정하는 TENT를 적용해 밝기 차이에 맞춤
- **R2 ResNet34 원본 해상도:** 세 밝기 표현을 입력으로 이미지를 줄이지 않고 원래 크기 그대로 처리, 가는 Eutectic Si 결합에 사용
- **R3 EfficientNet-B4 3 배 확대:** fold 2 개 평균을 1 개로 줄여도 결합 점수 변화가 적어 1 개만 사용. $Al_3Ni$는 R4~R6 과 절반씩 분담하고 AI 예측을 보조
- **R4~R6 EfficientNet-B4 가로 4000:** fold 1·3·4 평균을 사용. fold 2 를 더하면 검증 점수가 0.16%p, 2 개로 줄이면 0.06~0.29%p 떨어져 3 개 유지
- **R7 HRNet 드문 상 가중:** 기본 HRNet(U-Net++ 디코더·경계 보조 출력, 70 epoch, 최종 구성에는 미포함)에 Eutectic Si·Primary Si 오차 가중치를 줘 12 epoch 추가 학습. 단독 점수는 기본 HRNet보다 낮지만(표 4), 결합에서는 Al·Eutectic Si를 주로 맡고 기본 HRNet의 비중까지 겸함(그림 3)
- **E1~E2 EfficientNet-B4 추가 학습:** R4~R6 중 fold 1·3 을 BatchNorm 통계를 고정한 채 2,000 step 추가 학습(+0.38%p, 미고정 시 −0.10%p), R에 쓰면 결합 비율을 다시 골라도 이득이 없어 E에만 사용
- **E3 HRNet 세 밝기 입력:** 기본 HRNet을 세 밝기 표현 입력으로 25 epoch 추가 학습, R7 과 다른 입력으로 이미지를 봄
- **E4~E5 HRNet 가로 폭 정규화:** E4 는 fold 4, E5 는 학습용 70 장 전체로 학습. R의 HRNet과 다른 크기로 이미지를 보아 오류 중복 감소

□ ② **R 상별 결합:** 상마다 잘 맞히는 모델의 확률을 정해진 비율만큼 교체해 넣음(그림 3), ResNet34 고해상도 모델의 확률에서 시작해 차례로 교체, 교체할 때마다 네 상의 확률 합을 1 로 정규화

- 비율은 상마다 0~100% 중 검증 데이터로 선택, 우연 여부는 검증용 이미지를 하나씩 빼고 다시 고르는 교차 검증으로 확인(같은 번호의 2 장은 함께 제외)

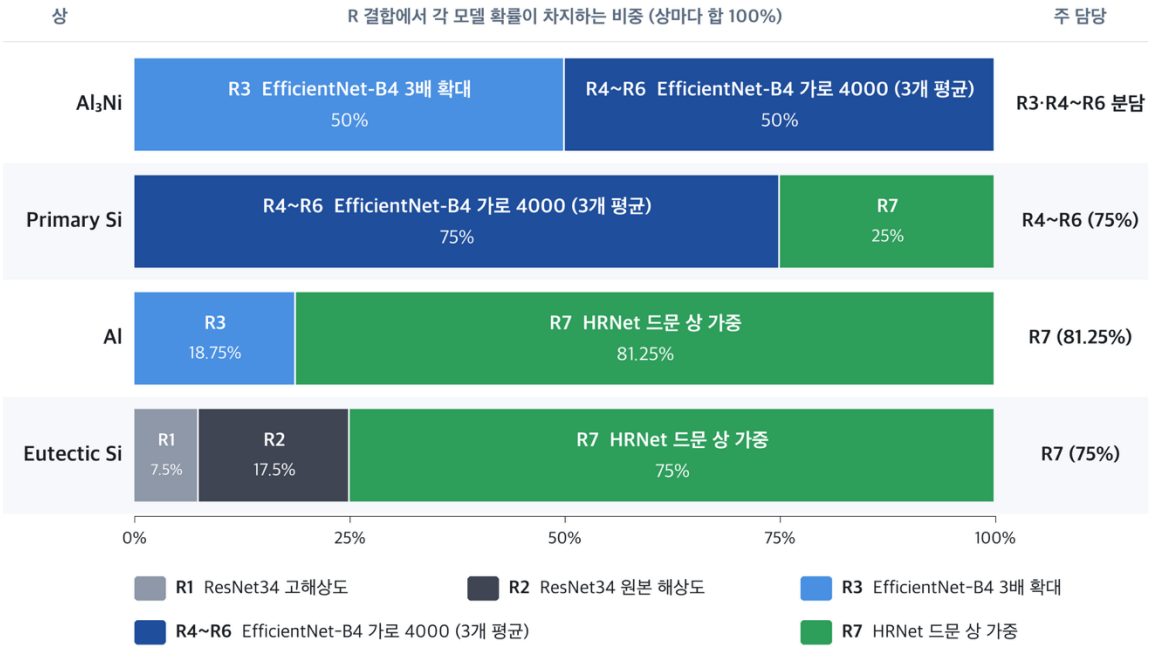



그림 3. 상별 최종 예측에 반영되는 모델 비중(결합 비중이며, 성능 기여도와는 다름)

□ ③ **후처리:** R의 결과를 세 가지 규칙으로 정리

- **밝기 보정:** 학습용 70 장에서 상별 상대 밝기 분포를 구하고(Z 평균: $Al_3Ni$ −0.54, Primary Si −1.94, Al +0.70, Eutectic Si −1.28), 픽셀마다 각 분포에 대한 정규분포 log 우도를 0.11 배로 log 확률에 더함, 이미지 평균 밝기 구간별 Al·Eutectic Si 보정값은 검증 데이터로 선택
- **작은 조각 정리:** 128 픽셀 이하 Primary Si 조각과 이미지의 1% 이하로만 나온 Primary Si를 다음으로 가능성이 높은 상으로 변경
- **경계 다듬기:** Primary Si와 Eutectic Si의 경계를 필터로 부드럽게 처리, 점수 변화는 거의 없으나 계단 모양 경계와 외딴 픽셀이 줄어 마스크가 실제 조직 모양에 가까워짐, 마스크로 입자 크기·모양을 잴 때 경계 잡음 감소를 기대

□ ④ **E 덮어쓰기:** R이 놓친 $Al_3Ni$·Al 픽셀을 E의 판단으로 교체

- E 결합: E1~E2(EfficientNet-B4) 평균 40%, E3·E4(HRNet) 평균 42%, E5(HRNet, 70 장 전체 학습) 18%로 확률을 더해 E의 예측 생성
- 교체 규칙: E가 $Al_3Ni$ 또는 Al로 판단한 픽셀은 R의 결과를 E의 결과로 바꾸고, 나머지 픽셀은 R의 결과 유지

□ ⑤ **F 보정:** F가 Al로 판단한 픽셀을 Al로 바꿔 최종 마스크 생성

- **구조:** E의 네 상 log 확률과 밝기(5 채널)를 입력받는 3 층 CNN, 한 픽셀이 보는 범위는 주변 7×7
- **보정 방식:** 픽셀마다 상별 확률을 얼마나 올리거나 내릴지(보정량)를 계산해 E의 log 확률에 더함, 보정량은 tanh로 상한을 두고 크기에 벌점을 줘 E의 예측을 크게 뒤집지 않도록 제한
- **학습:** 학습용 70 장에 대한 E의 OOF 예측(해당 이미지를 학습에 쓰지 않은 fold 모델의 예측)으로 8 epoch 학습

**3-3. 성능**

□ **검증 방법:** 학습용 70 장으로 학습한 최종 모델로 검증용 20 장 상 분할

□ **검증 점수:** 이미지별 네 상 IoU 평균(mIoU)의 20 장 평균 80.779378%

표 6. 최종 모델의 상별 검증 성능

| 상 | IoU | 재현율 | 정밀도 | 주로 헷갈린 상 |
|---|---|---|---|---|
| $Al_3Ni$ | 78.25% | 89.6% | 90.4% | Al |
| Primary Si | 87.33% | 95.1% | 95.4% | Eutectic Si |
| Al | 94.58% | 97.9% | 96.9% | $Al_3Ni$ |
| Eutectic Si | 62.96% | 77.1% | 80.8% | $Al_3Ni$ |
| 전체 평균 | 80.78% | – | – | – |

- **이미지별 점수:** 대부분 75~90%, 최저인 A71(53.63%)은 Primary Si가 원래 없어 규칙상 0 점이 포함됨(나머지 세 상 평균 71.51%)

□ **모델 규모:** 가중치 13 개(R 7 개·E 5 개·F 1 개), 총 1.95GB

□ **추론 시간:** RTX 5080(16GB) 1 장에서 모델 불러오기부터 최종 마스크까지 이미지당 약 30~50 초(검증용 20 장 11 분, 시험용 10 장 8 분)

□ **시험용 이미지 결과**

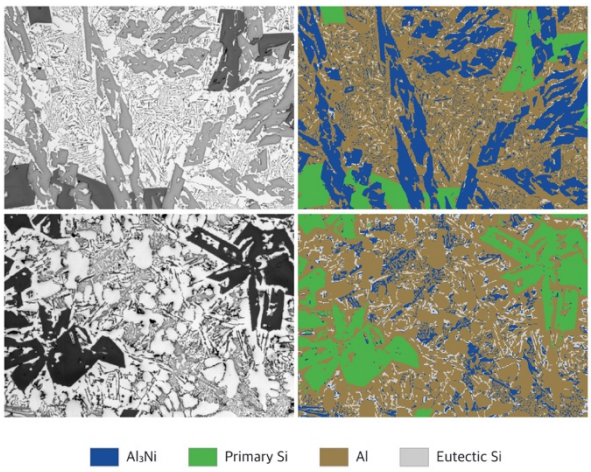



그림 4. 시험용 이미지의 원본(왼쪽)과 예측 마스크(오른쪽). 위: A107_step1_sample3, 아래: A51_step3_sample3

### ④ 추가 분석 및 발전 가능성

□ **상별 오류:** Al은 정답의 97.9%를 찾지만 Eutectic Si는 77.1%만 찾고 예측의 80.8%만 맞아 놓침·과잉 예측이 모두 많음(표 6)

- **점수가 낮은 이미지:** A71 은 없는 상(Primary Si)의 0 점이 포함됨. A153·A74 는 Eutectic Si IoU 31.5%·40.8%, A67·A11_step2 는 $Al_3Ni$ IoU 59.4%·64.8%로 특정 상의 오류가 큼

□ **경계 오류:** 오류의 88.4%가 경계 1 픽셀 이내에 집중되고 상 면적비 오차는 0.3~1.3%p(Primary Si 0.31, Eutectic Si 0.74, $Al_3Ni$ 1.15, Al 1.30%p)로 작아, 남은 개선 여지는 상을 통째로 놓치는 것보다 경계 정밀화에 있음

□ **상 쌍별 혼동:** 전체 오류의 73%가 $Al_3Ni$와 Al·Eutectic Si 사이에서 발생하고 그중 90%가 경계에 집중됨. Primary Si↔Eutectic Si 혼동(8.4%)만 경계 비율이 54%로 낮아, 같은 Si 상을 입자 단위로 잘못 분류함

□ **입자 크기:** 100 픽셀 미만 미세 입자의 재현율이 $Al_3Ni$ 68.3%, Eutectic Si 73.8%로 큰 입자(93~99%)보다 낮고, 각 상에서 놓친 픽셀의 약 40%를 차지 → 미세 입자 중심의 학습 샘플링 필요

□ **경계·형상 지표:** 경계 3 픽셀 폭으로 계산한 Boundary IoU는 69.9%로 mIoU보다 10.9%p 낮음. 10 픽셀 이상 입자의 개수·평균 크기 오차는 이미지별 중앙값 6~11% → 경계 학습을 강화하고 별도 시편에서 Boundary IoU·형상 오차로 효과 확인 필요

□ **검토 영역 선별:** R과 E의 판단이 다른 영역은 면적 2.75%이지만 오류율이 38.7%로 전체 평균(5.76%)의 6.7 배. E 확신도가 낮은 면적 10%만 검토해도 전체 오류의 62%를 찾음(무작위 선정 시 10%) → 전문가 검토·추가 라벨링 후보 선정에 활용 가능하며, 수정 시간 단축 효과 확인 필요

□ **경량화:** 가로 4000 픽셀 EfficientNet-B4 3 개를 1 개로 증류하면 가중치 2 개 축소 가능. 기존 시도는 실패해 학습 방식 개선 필요